사전 변동성 국면에 따른 실현변동성 예측 모델의 성능 비교

고빈도 암호화폐 자료를 중심으로 †

윤태준 * · 김채원 * · 손낙훈 * | * 계명대학교 자연과학대학 통계학과

연구 배경 및 목적

암호화폐 가격은 돌아올 기준점이 없는 비정상 시계열이다 . 그러나 흔들림의 크기인 변동성은 높은 상태와 낮은 상태가 몇 달씩 이어지고 , 직전 변동성이 다음 변동성을 설명한다 . 최근 어텐션 · 합성곱 · 사전학습 (파운데이션) 딥러닝 모델이 범용 시계열에서 높은 성능을 보고했지만 , 모델마다 입력과 학습 절차가 달라 무엇이 성능을 만드는지 섞여 있다 . 본 연구는 업비트 20 종목의 15 분봉으로 27 개 모델을 같은 조건에서 비교해 이 질문에 답한다 .

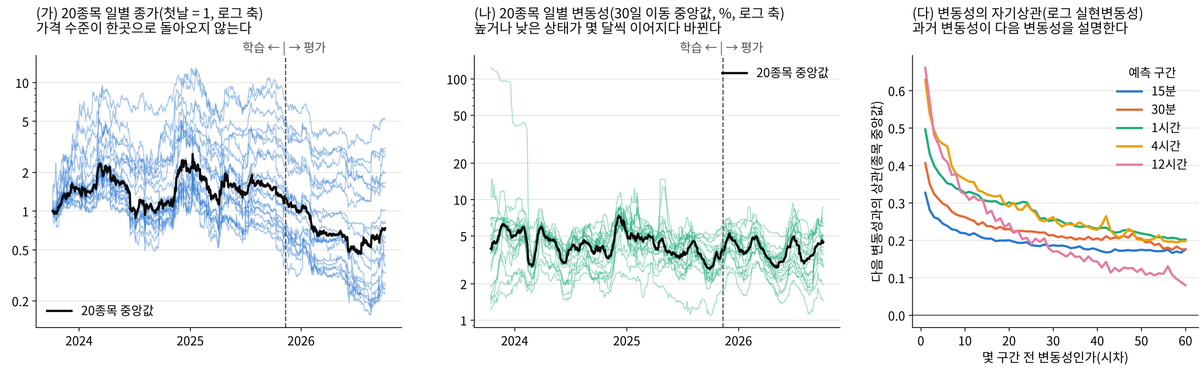


그림 1. 업비트 20 종목 (2023.10~2026.10). (가) 가격은 3 년 뒤 0.22~5.2 배로 흩어진다 . (나) 변동성은 높고 낮은 상태가 몇 달씩 이어진다 . (다) 직전 변동성과 다음 변동성의 상관은 0.33(15 분)~0.66(12 시간) 이다 .

선행 연구

수익률의 방향은 거의 예측되지 않지만 크기인 변동성은 상당 부분 예측된다는 것이 금융 시계열의 정형화된 사실이다 (Cont, 2001; Christoffersen & Diebold, 2006). 어텐션 모델 (PatchTST, iTransformer) 과 사전학습 파운데이션 모델 (Chronos, TimesFM) 은 범용 시계열 벤치마크에서 높은 성능을 보고했다 (Nie et al., 2022; Liu et al., 2023; Ansari et al., 2024; Das et al., 2023). 그러나 모델마다 입력 형태와 학습 절차가 달라 구조의 효과와 입력의 효과가 섞이며 , 변동성 예측에 파운데이션 모델을 견준 최근 연구 (Brini, 2026) 도 변동성 상태별 우열과 입력을 맞춘 비교는 다루지 않았다 .

연구 질문

본 연구는 아래 세 질문에 답한다 .

연구 질문	확인 방법	답이 있는 그림
1. 최신 딥러닝 모델은 기존 모델 (GARCH · 트리) 보다 변동성을 잘 예측하는가	27 개 모델을 같은 자료 · 같은 시각 정보 · 같은 채점으로 시장 상태별 비교하고 , 다른 시기 (2020~2023) 에서 다시 확인	그림 2 · 3 · 7
2. 차이가 있다면 과거를 읽는 방식 (구조) 때문인가 , 입력 형태 때문인가	순환 신경망과 병렬 딥러닝에 같은 입력을 주고 다시 비교	그림 4 · 6
3. 시장이 요동칠 때와 잔잔할 때 다른 모델을 써야 하는가	상태마다 1 위 모델을 바꿔 쓴 경우와 전체 기간 1 위를 그대로 쓴 경우를 비교	그림 3

분석 자료 및 방법

표 1. 자료와 실험 조건

항목	내용
자료	업비트 원화 20 종목 (거래대금 상위 10 + 변동성 상위 10), 15 분봉 , 2023.10~2026.10
예측 대상	다음 15 분 · 30 분 · 1 시간 · 4 시간 동안의 실제 변동성
학습 · 평가	2025.11.11 에 시간순으로 나눔 (학습 약 25 개월 , 평가 약 11 개월)
전처리	요일 × 시간대별 변동성 차이 (주기) 를 나눠 없앤 뒤 학습하고 , 예측은 원래 크기로 되돌려 채점
학습	신경망은 학습률 세 값을 시험해 고르고 검증 오차가 가장 작던 상태로 되돌림 , 모든 모델은 같은 시각까지의 정보로 예측
시장 상태	직전 변동성을 5 단계 (Q1 가장 잔잔 ~ Q5 가장 요동) 로 나눠 따로 비교
채점	QLIKE(작을수록 좋음), 두 모델 차이는 DM 검정 + Holm 보정 ($p < 0.05$)
반복 · 재현	학습하는 모델은 시드 20 개 , 2020.07~2023.07 과거 독립 기간에서 같은 비교를 다시 함

순차 방식은 과거를 한 시점씩 차례로 읽으며 기억을 다음 시점으로 넘기고 , 병렬 방식은 과거 구간을 한꺼번에 보고 판단한다 .

표 2. 비교한 27 개 모델

처리 방식	모델	입력
순차	GARCH-t, GARCH-BIC, MS-GARCH, TAR-GARCH, GRU, LSTM	15 분봉 수익률을 순서대로
병렬 · 특징 기반	LightGBM, XGBoost, HistGBM, GARCH-BIC+LightGBM, Nystroem+Ridge	15 분 ~1 주 여러 길이의 변동성 특징
병렬 · 딥러닝 (신규 15 종)	PatchTST, iTransformer, Autoformer, TimeXer, TCN, TimesNet, ModernTCN, S-Mamba, Chronos-Bolt, TimesFM, TTM, Moirai-2, Sundial, Time-MoE, Lag-Llama(마지막 7 종은 추가 학습 없이 예측)	예측 구간 단위로 묶은 변동성 수열
기준선	naive	직전 변동성 그대로

평가 방법

· 실제 변동성 : 예측 구간 동안의 15 분 수익률을 제곱해 더한 뒤 제곱근을 취한 값이다 . 예를 들어 1 시간 변동성은 15 분 수익률 4 개로 만든다 .

· 점수 (QLIKE): 예측한 흔들림이 실제와 얼마나 어긋났는지 재는 점수로 , 작을수록 좋다 . 위험을 실제보다 작게 예측한 경우를 더 크게 벌한다 .

· 시장 상태 : 예측하는 순간 이미 아는 직전 변동성의 크기로 다섯 단계로 나눈다 . Q1 은 가장 잔잔할 때 , Q5 는 학습 기간 기준 상위 20% 로 가장 요동칠 때다 .

· 우열 판정 : 두 모델의 점수 차이가 우연으로 생길 수 있는 범위를 넘는지 DM 검정으로 확인하고 , 비교를 여러 번 하므로 Holm 보정을 한다 ($p < 0.05$). 차이가 확인되지 않으면 ' 구분 안 됨 ' 이며 , 이는 성능이 같다는 뜻은 아니다 .

· 지표 선택 : 실제 변동성은 15 분 수익률 몇 개로 계산한 근사값이라 측정 잡음이 크다 . 잡음이 섞인 값으로 채점해도 모델 순위가 뒤바뀌지 않는 손실은 QLIKE 와 MSE 계열뿐이다 (Patton, 2011). MSE 는 변동성이 큰 몇 종목이 합계를 정하므로 , 종목마다 변동성 크기가 달라도 비교할 수 있는 QLIKE 를 주 지표로 썼다 . 결정계수 ($MZ R^2$) 와 MAE 는 잡음 때문에 순위가 뒤바뀔 수 있어 판정에 쓰지 않았고 , 예측의 실제 쓸모는 손실 한도 (VaR) 백테스트와 변동성 목표 포지션으로 따로 확인했다 .

결 과

최신 딥러닝 (갈색) 은 전체 기간에서 1 위가 되지 못했고 , 가장 요동칠 때 (Q5) 는 15 분 ~4 시간 모두 1 위보다 유의하게 나빴다

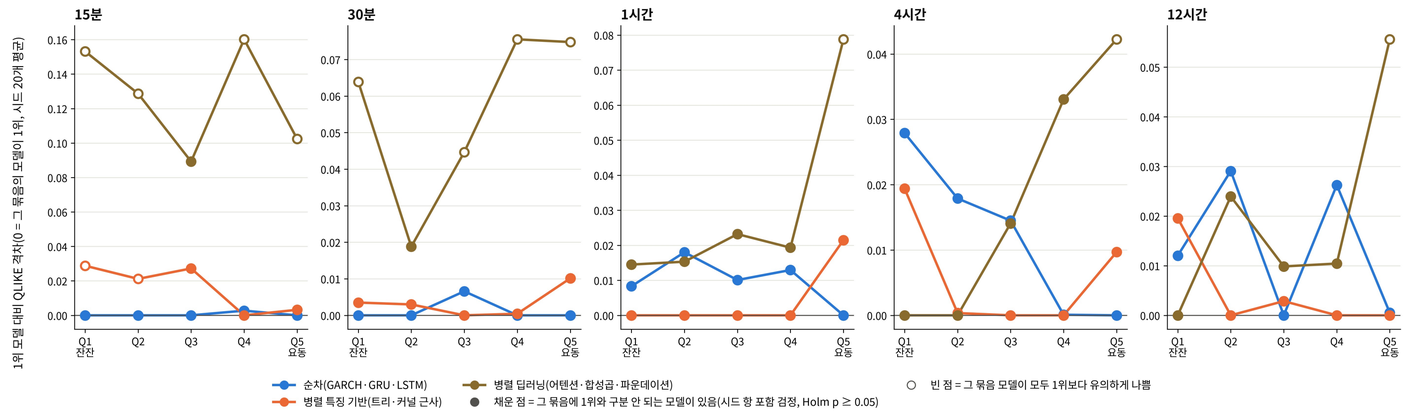


그림 2. 예측 구간 (칸) 마다 , 시장 상태 Q1(잔잔)~Q5(요동) 에서 처리 방식별로 가장 나은 모델이 1 위와 얼마나 차이 나는지 (0 = 그 방식의 모델이 1 위). 파랑 순차 , 주황 특징 기반 , 갈색 딥러닝 . 빈 점 = 그 방식의 모델이 모두 1 위보다 유의하게 나쁨 , 채운 점 = 1 위와 구분 안 되는 모델이 있음

그림 2 해석

1. 갈색 선 (딥러닝) 은 거의 모든 칸에서 가장 위에 있다 . 가장 요동칠 때 (Q5) 는 다섯 구간 모두 빈 점으로 , 딥러닝 15 종 모두 1 위보다 유의하게 나빴다 (1 위와의 차이 15 분 0.10, 30 분 0.075, 1 시간 0.079, 4 시간 0.042).

2. 1 시간 · 4 시간에서 갈색 선은 시장이 요동칠수록 대체로 올라가 Q5 에서 가장 높다 (4 시간 : Q1 0 → Q5 0.042). 잔잔할 때는 딥러닝도 1 위와 비슷하지만 , 요동칠수록 뒤처진다 .

3. 파랑 선 (순차) 은 Q5 에서 다섯 구간 모두 0 에 붙는다 . 15 분 ~4 시간에서 가장 요동칠 때 1 위는 순차 모델 (15 · 30 분 GARCH-BIC, 1 · 4 시간 GRU) 이었고 , 15 · 30 분은 모든 상태에서 0 근처다 .

4. 주황 선 (특징 기반) 은 1 시간 Q1~Q4 와 4 시간 Q3 · Q4 에서 1 위이고 , 4 시간 Q2 에서도 1 위와 거의 같다 . 평소에는 트리 · 커널이 강하다는 뜻이다 . 다만 전체 기간 1 위를 그대로 써도 요동 때 1 위와 통계적 차이가 없어 (그림 3), 상태마다 모델을 바꿀 이득은 없다 . 12 시간은 선이 얽히고 차이가 작아 참고로만 본다 .

가장 요동칠 때 1 위는 네 구간 모두 순차 모델 (15 · 30 분 GARCH-BIC, 1 · 4 시간 GRU) 이었다 . 그러나 전체 기간 1 위를 그대로 써도 요동 때 1 위와 통계적 차이가 없어 , 상태마다 모델을 바꾸는 이득은 없었다

	15분	30분	1시간	4시간
전체 기간	GARCH-BIC 구분 안 됨 0종	GARCH-BIC 구분 안 됨 0종	GARCH-BIC+LightGBM 구분 안 됨 2종	GARCH-BIC+LightGBM 구분 안 됨 15종
Q1 가장 잔잔	GARCH-BIC 구분 안 됨 0종	GARCH-BIC 구분 안 됨 4종	GARCH-BIC+LightGBM 구분 안 됨 10종	TimesFM 구분 안 됨 12종
Q2	GARCH-BIC 구분 안 됨 0종	GARCH-BIC 구분 안 됨 7종	LightGBM 구분 안 됨 15종	PatchTST 구분 안 됨 16종
Q3	GARCH-BIC 구분 안 됨 4종	GARCH-BIC+LightGBM 구분 안 됨 5종	XGBoost 구분 안 됨 7종	Nystroem+Ridge 구분 안 됨 19종
Q4	Nystroem+Ridge 구분 안 됨 5종	GARCH-BIC 구분 안 됨 8종	GARCH-BIC+LightGBM 구분 안 됨 5종	Nystroem+Ridge 구분 안 됨 9종
Q5 가장 요동	GARCH-BIC 구분 안 됨 1종	GARCH-BIC 구분 안 됨 4종	GRU 구분 안 됨 7종	GRU 구분 안 됨 7종

칸 = 그 구간·국면의 QLIKE 1위 모델, 색 = 1위의 묶음, 구분 안 됨 = 1위와 통계적으로 구분되지 않는 다른 모델 수(Holm 보정), 적을수록 진함
순차: GARCH 4종·GRU·LSTM　병렬(특징 기반): 트리·커널·하이브리드　병렬(딥러닝): 신경망 8종·파운데이션 7종

그림 3. 구간 × 시장 상태별 1 위 모델 . 칸 색 = 1 위의 처리 방식 , 괄호 = 1 위와 구분 안 되는 모델 수 . 빨간 상자 = 가장 요동칠 때 (15 · 30 분 GARCH-BIC, 1 · 4 시간 GRU)

평소에는 트리 · 커널이 순차보다 나은 칸이 많았고 , 요동칠 때 순환 신경망의 우위는 입력을 똑같이 맞추면 사라졌다



그림 4. 15 분 ~4 시간 × 6 개 상태 = 24 칸에서 두 묶음의 평균 점수를 검정한 결과 (칸 수). 같은 GRU · LSTM 에서 15 분봉 입력은 묶은 입력보다 요동 때 점수를 0.042~0.090 줄였다

1 위권 모델은 학습도 가장 빨랐다

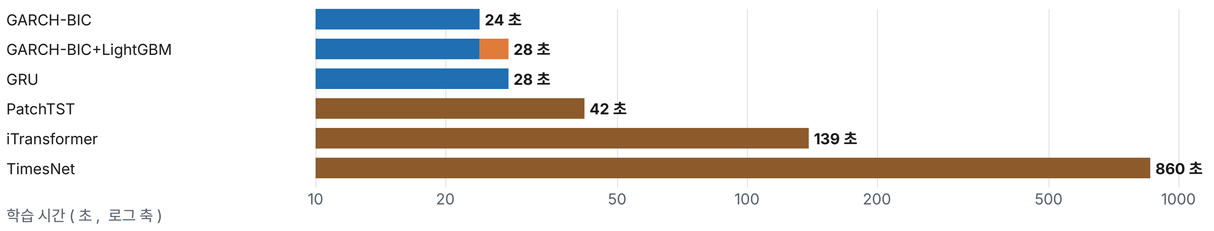


그림 5. 모델별 학습 시간 (종목 · 시드당 5 구간 , 중앙값 , 로그 축). GARCH-BIC+LightGBM 은 GARCH-BIC 예측을 만드는 시간을 포함한다 . 사전학습 파운데이션은 추가 학습 없이 예측한다

요동칠 때는 직전 구간 안의 흐름이 다음 변동을 설명했고 , 이 흐름은 15 분봉을 그대로 받는 모델만 볼 수 있다

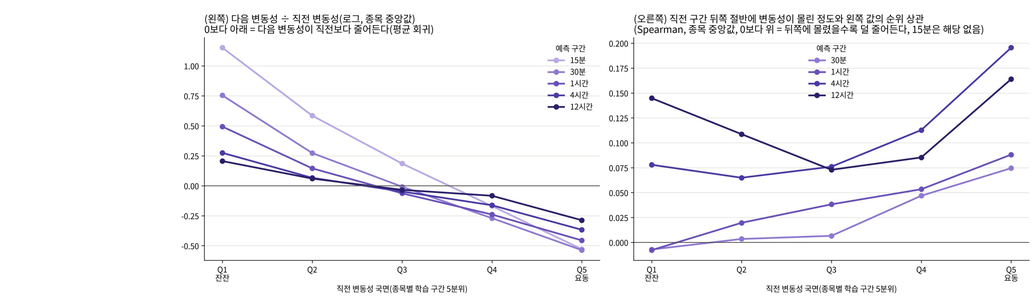


그림 6. 왼쪽 : 다음 변동성 ÷ 직전 변동성 (로그 , 종목 중앙값). 잔잔할 때는 커지고 요동칠 때는 줄어든다 . 오른쪽 : 직전 구간 안에서 변동이 뒤쪽 절반에 몰린 정도와 왼쪽 값의 순위 상관 . 요동칠 때 모든 구간에서 양수이고 , 30 분 · 1 시간 · 4 시간은 잔잔할 때보다 유의하게 크다

다른 시기 (2020~2023) 에서도 직접 학습한 딥러닝은 요동 때 40 번 중 37 번 1 위보다 나빴다

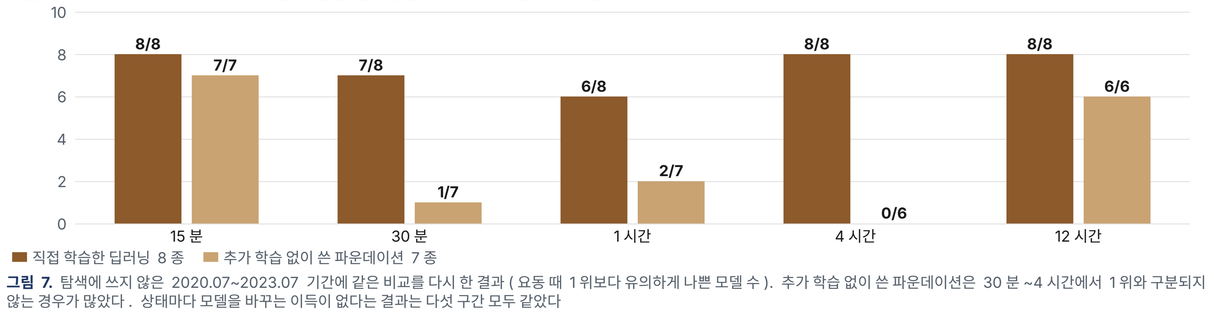


그림 7. 탐색에 쓰지 않은 2020.07~2023.07 기간에 같은 비교를 다시 한 결과 (요동 때 1 위보다 유의하게 나쁜 모델 수). 추가 학습 없이 쓴 파운데이션은 30 분 ~4 시간에서 1 위와 구분되지 않는 경우가 많았다 . 상태마다 모델을 바꾸는 이득이 없다는 결과는 다섯 구간 모두 같았다

결 론

요약 및 논의

1. 최신 딥러닝 15 종은 15 분 ~4 시간 어느 구간에서도 전체 기간 1 위 모델 (GARCH-BIC, GARCH-BIC+LightGBM) 을 이기지 못했고 , 가장 요동칠 때는 59 번의 비교 모두에서 1 위보다 유의하게 나빴다 (그림 2 · 3).

2. 요동칠 때 순환 신경망이 병렬 딥러닝보다 나은 이유는 구조가 아니라 입력이다 . 같은 입력을 주면 차이가 사라졌고 , 15 분봉 입력만으로 점수가 0.042~0.090 좋아졌다 (그림 4 · 6).

3. 변동성 예측은 요동 때 GARCH · GRU 같은 순차 모델 , 평소 1 · 4 시간은 GARCH-BIC+LightGBM 에서 시작하고 , 구조보다 입력을 먼저 개선하며 , 시장 상태별로 모델을 바꾸지 않는 것이 맞다 (그림 2 · 3).

4. 다른 시기 (2020~2023) 에서도 직접 학습한 딥러닝의 요동 때 열세 (37/40) 와 상태 교체 이득 없음 (5/5) 이 재현되었고 (그림 7), 아래 추가 분석에서도 결론은 바뀌지 않았다 .

한계

· 결론은 암호화폐 20 종목 , 15 분봉 , 종가 기준 변동성 , QLIKE 에 한정된다 .

· ' 구분 안 됨 ' 은 성능이 같다는 증명이 아니다 .

· 12 시간은 평가 시각이 적어 대부분 모델이 1 위와 구분되지 않아 본문에서 뺐다 .

· 과거 기간의 KRW-BTT 는 호가 한 칸이 가격의 8~17% 라 15 분 변동성이 가격 변화보다 호가 사이 왕복을 잰다 .

추가 분석

분석	수행 이유	결과
고가 · 저가 폭으로 채점	15 분 수익률로 잰 변동성에는 잡음이 있어 , 다른 측정으로 채점해도 순위가 같은지 확인	모델 순위 상관 0.92~0.97, 결론 동일
종목 단위 검정	20 종목 평균이 일부 종목에 끌려간 결과인지 보려고 종목을 단위로 다시 검정	결론 동일
신경망 학습 예산 동일	모델마다 학습량이 달라 구조 차이에 학습량 차이가 섞일 수 있어 , 학습량을 맞춰 다시 비교	요동 때 순환 신경망 우세 유지
분할 시각 두 번 이동	한 평가 기간의 우연인지 보려고 학습 · 평가 경계를 앞당겨 다시 학습	순환 우세와 상태 교체 이득 없음 유지

분석	수행 이유	결과
평가 기간 3 개 묶음 (약 23 개월)	세 평가 기간을 합쳐 표본을 늘려도 같은지 확인	4 시간까지 순환 우세 유의
파운데이션 추가 학습	추가 학습 없이 쓴 것이 파운데이션 모델에 불리했는지 확인	138 칸 중 82 칸 개선 , 1 위보다 나은 칸 없음
여러 모델 결합 7 종	한 모델을 고르는 대신 여러 예측을 섞으면 1 위를 넘는지 확인	1 위를 안정적으로 이기지 못함
위험 관리 쓸모 (VaR 백테스트 · 변동성 목표)	점수 차이가 손실 한도와 포지션 크기 같은 실제 쓰임에서도 차이로 나타나는지 확인	손실 한도 위반은 GARCH 계열 · 특징 기반이 가장 덜 몰렸고 (15 분 ~1 시간 기각 1~3 종목), 포지션은 GARCH-BIC 와 순환 신경망이 가장 안정

† 이 성과는 정부 (과학기술정보통신부) 의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (RS-2025-00558517)